

Fouille de données


10/09 2023

1. Méthodes de regression

1.1 Regression linéaire Univariée (avec une seule variable)

• data $D = \{(x_1, y_1), \dots, (x_n, y_n)\}$

Exemple de l'agence immobilière on a $\begin{cases} x = \text{surface} \\ y = \text{prix du bien} \end{cases}$



→ hypothèse :

$$h_\theta(x) = \theta_0 + \theta_1 x \quad \text{avec } \theta = \{\theta_0, \theta_1\}$$

paramètres $\in \mathbb{R}^2$

→ Objectif

Trouver les valeurs θ_0 et θ_1 qui permettent de définir le modèle (droite) qui s'appelle le plus des données
= "modélisé"

$$\text{Erreur} = h_\theta(x_i) - y_i$$

→ Minimiser l'erreur moyenne sur tous les pts de D .

$$J_\theta(\theta_0, \theta_1) = \frac{1}{n} \sum_{i=0}^n |h_\theta(x_i) - y_i|$$

$$\min_{\theta_0, \theta_1} J(\theta_0, \theta_1) = \frac{1}{n} \sum \dots$$

$$\min f(x) = ? \quad f'(x) = 0?$$

$$\min f(x) = x^2, \quad f'(x) = 2x = 0 \text{ ssi } \boxed{x = 0}$$


on pose

pt	1	2	3	4	5
erreur	2	-2	3	1	-3

$\Rightarrow \sum_{\text{erreur}} = 1$

La fct absolue n'est pas dérivable!
→ c'est pour ça on a ajouté le carré dans la formule de Σ .

$$|h_{\theta}(x_i) - y_i| = 1.1$$



L'algorithme du Gradient = algo qui sert à minimiser la f^{ct} coût $J(\theta_0, \theta_1)$

REGLÉ DE MISE À JOUR:

$$\theta_i = \theta_i - \alpha \frac{\partial J}{\partial \theta_i} \text{ avec } 0 < \alpha < 1$$


$$\begin{aligned} \text{on a } \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_0} &= \frac{\partial}{\partial \theta_0} \left[\frac{1}{2m} \sum_{i=1}^m (\theta_0 + \theta_1 x_i - y_i)^2 \right] \\ &= \frac{1}{2m} \sum_{i=1}^m \frac{\partial}{\partial \theta_0} (\theta_0 + \theta_1 x_i - y_i)^2 \\ &= \frac{1}{2m} \sum_{i=1}^m \cancel{2} (\theta_0 + \theta_1 x_i - y_i) \times \underline{\underline{1}} \end{aligned}$$

$$\begin{aligned} \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_1} &= \frac{1}{2m} \sum_{i=1}^m \frac{\partial}{\partial \theta_1} (\theta_0 + \theta_1 x_i - y_i)^2 \\ &= \frac{1}{2m} \sum_{i=1}^m \cancel{2} (\theta_0 + \theta_1 x_i - y_i) \underline{\underline{x_i}} \\ &= \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 x_i - y_i) \underline{\underline{x_i}} \end{aligned}$$

Algorithme de Gradient =

3

init $\theta_0^{old}, \theta_1^{old}$ (aléatoire)
 $J_{old} \leftarrow J(\theta_0^{old}, \theta_1^{old})$
 Répéter
 $\theta_0 \leftarrow \theta_0^{old} - \alpha \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_0}$ (hyperparamètre α , paramètre)
 $\theta_1 \leftarrow \theta_1^{old} - \alpha \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_1}$
 $J \leftarrow J(\theta_0, \theta_1); \theta_0^{old} \leftarrow \theta_0; \theta_1^{old} \leftarrow \theta_1$
 $J_{avant} \leftarrow J_{old}; J_{old} \leftarrow J$
 - Jusqu'à $(J_{avant} - J) \leq \epsilon$
 Retrouver (θ_0, θ_1)



La machine apprend?

$\alpha \in \mathbb{R}$: le taux d'Apprentissage

1.2: Regression lineaire multivariée

Données $\begin{pmatrix} x_1 & x_2 & \dots & x_n & y \\ x_{11} & x_{12} & \dots & x_{1n} & y_1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \dots & x_{mn} & y_m \end{pmatrix}$ $\begin{matrix} i=1 \\ \vdots \\ i=m \end{matrix}$

$$\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

Hypothèse

$$h_0(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_m x_m$$

$$= \theta_0 + \sum_{i=1}^m \theta_i x_i \quad \text{Avec } \theta = \{\theta_0, \theta_1, \theta_2, \dots, \theta_m\} \in \mathbb{R}^{n+1}$$

Erreur $= h_0(x_i) - y_i$

1-er coût $= J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_0(x_i) - y_i)^2$ est le i^{em} élément de l'ensemble I

Calcul des dérivées

$$\frac{\partial J(\theta)}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x_i) - y_i) x_1$$

$$\frac{\partial J(\theta)}{\partial \theta_i} = \frac{1}{m}$$

$$h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3$$

→ Changer d'hyperparamètres (dont dépend la méthode)


1.3. Sur / Sous Apprentissage

Regression polynomiale $h_{\theta}(x) = \theta_0 + \sum_{i=1}^p \theta_i x^i$

1.4. Regression Logistique

pb: spam (mails)

$$\text{sigmoid}(z) = \frac{1}{1 + e^{-z}}$$



Cost

$$h_{\theta}(x) = g\left(\underbrace{\theta_0 + \sum_{i=1}^m \theta_i x_i}_{\in \mathbb{R}}\right)$$

$\in]0, 1[$

$$\text{cost}(h_{\theta}(x_i), y_i) = \frac{1}{2} (h_{\theta}(x_i) - y_i)^2$$

$$\text{cost}(h_{\theta}(x_i), y_i) = \frac{1}{2} (h_{\theta}(x_i) - y_i)^2 = \text{cost}(h_{\theta}(x_i), y_i)$$


$$= -\log(h_{\theta}(x_i))$$

$$\left. \begin{array}{l} \text{CS} \\ \text{Si } y_i = 1 \end{array} \right\}$$


$$\cos(h_\theta(x_i, y_i)) = -\log(1 - h_\theta(x))$$

$$\text{si } y_i = 0$$

$$f(x) = -\log(1-x) \text{ sur } x \in]0, 1[$$




$$-\log(h_\theta(x))$$



$$h_\theta(x) \rightarrow 1$$

$$\cos(h_\theta(x)) \rightarrow 0$$

$$-\log(1 - h_\theta(x))$$



$$\cos(h_\theta(x_i), y_i) = \begin{cases} -\log(h_\theta(x)) & \text{si } y_i = 1 \\ -\log(1 - h_\theta(x)) & \text{si } y_i = 0 \end{cases}$$

$$\cos(h_\theta(x_i), y_i)$$

$$= -y_i \log(h_\theta(x_i)) - (1 - y_i) \log(1 - h_\theta(x_i))$$

$$y_i = 1$$

$$y_i = 0$$

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \cos(h\theta(x_i), y_i)$$

J. Régularisation

Situation: $J(\theta) \sim 0$, mais le modèle ne généralise pas bien (mauvaises performances)

$$\Rightarrow \text{coût} = J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h\theta(x_i) - y_i)^2 + \underbrace{\frac{\lambda}{2m} \sum_{i=1}^m \theta_i^2}_{\text{hyperparamètres}} \Rightarrow \text{Régularisation}$$

Feature Scaling (Normalisation)



Donnée $\{x_1, x_2, \dots, x_n\}$

$$x_i' = \frac{x_i - \min(x_i)}{\max(x) - \min(x_i)} \quad \text{ou} \quad x_i = \frac{x_i - \bar{x}_i}{s} \leftarrow \begin{matrix} \text{moyenne}(x_i) \\ \text{ecartType}(x_i) \end{matrix}$$


Perceptron (Approche Réseau de neurones)

NN = motivation

Apprendre des modèles non linéaires



$\{-30, 20, 20\}$: poids





x_1	x_2	$h_0(x)$
0	0	$g(-30) \sim 0$
0	1	$g(-10) \sim 0$
1	0	$g(-10) \sim 0$
1	1	$g(10)$

$$\theta_0 + \theta_1 x_1 + \theta_2 x_2$$



\uparrow \uparrow \uparrow
 -30 20 20

OR




0	0	0
1	0	1
0	1	1
1	1	1

NOT



x_1	$h_0(x)$
0	1
1	0



0	0	1
0	1	0
0	1	0
1	1	1